

# 模糊控制导论

苏临之

[sulinzhi029@nwu.edu.cn](mailto:sulinzhi029@nwu.edu.cn)




# 模糊控制导论纲要

- 模糊控制基本概念
- 模糊集合及其运算
- 模糊关系的数学表示和运算
- 模糊控制逻辑基础与推理运算
- 模糊C均值聚类法
- 科技文献书写和阅读


# 聚类

- 把性质相似的事物聚在一起形成一个类，这个过程称之为聚类（Clustering）。
- 请思考：右侧的这些图形可以聚成几类？都有哪几类？



# 聚类

- 把性质相似的事物聚在一起形成一个类，这个过程称之为聚类（Clustering）。
- 右侧的图形中，如果就形态性质聚类则可以聚成三角、圆和方三类；如果就颜色性质聚类，则可以聚成红色和蓝色两类。当然可以按照别的性质进行聚类。






# 数据性质的量化

- 计算智能中，所有事物的性质都是需要量化的。如颜色可以用通道灰度数值来表示，位置可以用坐标来表示。而形态则需要用更复杂的深度特征来表示。
- 需要注意的是，性质的数据化表示不一定是某一个数字，有可能是一个多维的向量，甚至是矩阵或其他多维阵列。例如常用的颜色性质数据就是由RGB构成的三维向量。这些被量化的性质可以通过计算来进行聚类。

# 聚类方法

- 常用的聚类方法有两种：一种是K均值法聚类(K-means, KM)，它是硬聚类法；另一种是模糊C均值聚类法(Fuzzy c-means, FCM)，它是软聚类法。其余算法基本上是对它们的改进处理。





# KM算法基本思想

- KM算法的基本思想是：把 $n$ 个数据 $x_j$  ( $j=1,2,\dots,n$ )分为 $m$ 个类组 $H_i$  ( $i=1,2,\dots,m$ )，并求每组 $H_i$ 的聚类中心 $c_i$ ，使目标函数 $J$ 达到最小。
- 在基本思想里，有两个比较重要的点值得关注：聚类中心 $c_i$  和目标函数 $J$ 。算法本身就是不断通过迭代的方式，通过优化代价函数 $J$ 的寻找诸聚类中心 $c_i$ ，进一步明确各个元素所属的类别。





# 聚类中心

- 聚类中心可以定义为当前分类时每一类的数据的算术平均值。假设类别 $H_i$ 中元素的个数是 $|H_i|$ ，则聚类中心 $c_i$ 可以计算如下：

$$c_i = \frac{1}{|H_i|} \sum_{x \in H_i} x$$





# 目标函数

- 目标函数 $J$ 是对当前分类结果的评价函数。如果函数值偏大，则分类结果较差；如果函数值较小，则分类结果较好。根据这个要求，可以用各个元素到聚类中心的欧几里得距离总和来构建 $J$ 。

$$J = \sum_{i=1}^m \sum_{x \in H_i} \|x - c_i\|^2$$



# 聚类中心和目标函数的初始化

- KM是迭代算法，因此首先必须要对聚类中心进行初始化。由于聚类的类别数 $m$ 已知，因此常用的方法是从中任意选择 $m$ 个元素作为聚类中心。然后通过公式计算初始目标函数值。这里使用上标(1)表示第1次迭代过程。

$$c_i^{(1)} = t_i \quad t_i = \text{rand}(x)$$

$$J^{(1)} = \sum_{i=1}^m \sum_{x \in H_i} \|x - c_i^{(1)}\|^2$$



# 元素类别的划分

- 当进行第 $k$ 次迭代计算时，得到了诸聚类中心 $c_i^{(k)}$ ，这样就可以计算每个元素 $x$ 到诸聚类中心的距离 $d_i^{(k)}$ 。 $x$ 到哪一类中心的距离最短，则就把 $x$ 划归到哪一类。

$$d_i^{(k)} = \|x - c_i^{(k)}\|$$

$$d_r^{(k)} = \min \{d_i^{(k)}\}$$

$$x \in H_r^{(k)}$$



# 聚类中心的更新

- 对所有元素 $x$ 进行分类以后，每一个元素都有类别标签，此时需要根据这个标签更新聚类中心。并计算新的目标函数值。

$$c_i^{(k+1)} = \frac{1}{|H_i^{(k)}|} \sum_{x \in H_i^{(k)}} x$$

$$J^{(k+1)} = \sum_{i=1}^m \sum_{x \in H_i^{(k)}} \|x - c_i^{(k+1)}\|^2$$



# 迭代终止条件

- 上述过程反复循环迭代。为了结束算法循环，需要一个终止条件。最常用的终止条件就是目标函数值几乎不再变化，这里使用足够小的正数 $\delta$ 来体现。

$$\left| J^{(k+1)} - J^{(k)} \right| \leq \delta$$

- 如果上述条件满足，则退出迭代循环，输出每个元素的标签作为最终聚类结果；如果上述条件不满足，则令 $k:=k+1$ ，继续循环计算距离并更新聚类中心和目标函数，直到终止条件满足为止。



# KM子程序的调用

- MATLAB 自带kmeans函数，可以直接调用。有以下几种常用调用方式。

```
U=kmeans (x,m)
```


```
[U,c]=kmeans (x,m)
```

```
[U,c,sum_dist]=kmeans (x,m)
```

```
[U,c,sum_dist,dist]=kmeans (x,m)
```

# 实验数据1


- 第一组数据，区分大，数量较少，以平面点位置为特征：






# 实验结果

- 聚类数 $m=2$ 结果如下:




# 实验结果

- 聚类数 $m=3$ 结果如下：




# 实验结果

- 聚类数 $m=4$ 结果如下:




# 实验数据2

- 第二组数据，区分度略小，数量略多：




# 实验结果

- 聚类数 $m=2$ 结果如下：




# 实验结果

- 聚类数 $m=3$ 结果如下：



# 实验结果


- 聚类数 $m=4$ 结果如下：






# 实验数据3

- 使用另一组区分度更小、点数更多的数据如下：




# 实验结果

- 聚类数 $m=2$ 结果如下：




# 实验结果

- 聚类数 $m=3$ 结果如下：



# 实验结果

- 聚类数 $m=4$ 结果如下：




# KM算法中的隶属度矩阵

- 最后对元素的聚类标签，实际上相当于生成一个隶属度矩阵，它是一个布尔矩阵。例如有5个元素，分3类，则它的隶属度矩阵 $U$ 如下：

$$x_1 = (1,1) \quad x_2 = (1,1.5) \quad x_3 = (2,4)$$

$$x_4 = (2,3.5) \quad x_5 = (4,4)$$

$$U = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$





# 目标函数的另一种形式


- 利用隶属度矩阵，目标函数 $J$ 可写成另一种形式。设元素 $j$ 对于第 $i$ 类的隶属度值是 $u_{ij}$ ，则有：

$$J = \sum_{i=1}^m \sum_{j=1}^n u_{ij} \|x_j - c_i\|^2$$

$$\sum_{i=1}^m u_{ij} = 1$$

# 从KM算法到FCM算法

- 如果隶属度矩阵取值范围不是 $\{0,1\}$ 而是 $[0,1]$ ，就得到了FCM算法。因此KM被称为硬聚类法，而FCM则是软聚类法。







# FCM算法的目标函数

- FCM算法的目标函数如下，其隶属度取值范围是 $[0,1]$ 。 $\alpha \in (1, +\infty)$ 是一个加权参数。因此本质上就是在隶属度和为1的条件下求 $J$ 的最小值。

$$J = \sum_{i=1}^m \sum_{j=1}^n u_{ij}^{\alpha} \|x_j - c_i\|^2$$

$$\sum_{i=1}^m u_{ij} - 1 = 0 \quad \forall j = 1, 2, \dots, n$$

# 拉格朗日目标函数构造

- 使用拉格朗日乘子法构建新的目标函数。这个函数中包括三类变量， $u_{ij}$ 、 $c_i$ 和 $\lambda_j$ 。为了求出这个函数的最小值，需要对其中的每一个变量求偏导数，并使得偏导数等于0。

$$\bar{J} = \sum_{i=1}^m \sum_{j=1}^n u_{ij}^{\alpha} \|x_j - c_i\|^2 + \sum_{j=1}^n \lambda_j \left( \sum_{i=1}^m u_{ij} - 1 \right)$$



# 聚类中心的更新公式

- 对聚类中心求偏导数，并令其为0，有：

$$\frac{\partial \bar{J}}{\partial c_i} = 2 \sum_{j=1}^n u_{ij}^{\alpha} (c_i - x_j) = 0$$

$$\Rightarrow c_i = \frac{\sum_{j=1}^n u_{ij}^{\alpha} x_j}{\sum_{j=1}^n u_{ij}^{\alpha}}$$

# 隶属度的更新公式

- 对隶属度求偏导数，并令其为0，可以得到隶属度更新原始公式。这个式子里含有参数 $\lambda_j$ ，必须进一步消掉。

$$\frac{\partial \bar{J}}{\partial u_{ij}} = \alpha \|x_j - c_i\|^2 u_{ij}^{\alpha-1} + \lambda_j = 0$$

$$\Rightarrow u_{ij} = \left( \frac{-\lambda_j}{\alpha \|x_j - c_i\|^2} \right)^{\frac{1}{\alpha-1}}$$

# 隶属度的更新公式

- 把这个表达式代入约束条件中，有：

$$\begin{aligned} \because \sum_{i=1}^m u_{ij} &= 1 \quad u_{ij} = \left( \frac{-\lambda_j}{\alpha \|x_j - c_i\|^2} \right)^{\frac{1}{\alpha-1}} \\ \therefore \sum_{i=1}^m \left( \frac{-\lambda_j}{\alpha \|x_j - c_i\|^2} \right)^{\frac{1}{\alpha-1}} &= \left( \frac{-\lambda_j}{\alpha} \right)^{\frac{1}{\alpha-1}} \sum_{i=1}^m \left( \frac{1}{\|x_j - c_i\|^{\frac{2}{\alpha-1}}} \right) = 1 \end{aligned}$$

# 隶属度的更新公式

$$\left(\frac{-\lambda_j}{\alpha}\right)^{\frac{1}{\alpha-1}} \sum_{i=1}^m \left( \frac{1}{\|x_j - c_i\|^{\frac{2}{\alpha-1}}} \right) = 1$$

$$\Rightarrow \left(\frac{-\lambda_j}{\alpha}\right)^{\frac{1}{\alpha-1}} = \frac{1}{\sum_{i=1}^m \left( \frac{1}{\|x_j - c_i\|^{\frac{2}{\alpha-1}}} \right)} = \frac{1}{\sum_{k=1}^m \left( \frac{1}{\|x_j - c_k\|^{\frac{2}{\alpha-1}}} \right)}$$

# 隶属度的更新公式

- 代回更新公式，避免变量冲突，将求和变量改为 $k$ 。

$$\begin{aligned} u_{ij} &= \left( \frac{-\lambda_j}{\alpha \|x_j - c_i\|^2} \right)^{\frac{1}{\alpha-1}} = \left( \frac{-\lambda_j}{\alpha} \right)^{\frac{1}{\alpha-1}} \cdot \frac{1}{\|x_j - c_i\|^{\frac{2}{\alpha-1}}} \\ &= \frac{1}{\sum_{k=1}^m \left( \frac{1}{\|x_j - c_k\|^{\frac{2}{\alpha-1}}} \right)} \cdot \frac{1}{\|x_j - c_i\|^{\frac{2}{\alpha-1}}} \end{aligned}$$





# 隶属度的更新公式

- 这样就得到了隶属度更新公式最终表达式:

$$u_{ij} = \frac{1}{\sum_{k=1}^m \left( \frac{\|x_j - c_i\|}{\|x_j - c_k\|} \right)^{\frac{2}{\alpha-1}}}$$



# 更新公式总结

- 在FCM迭代循环中，聚类中心和隶属度两者用以下公式更新。在实际操作中，可以通过随机数生成一批初始隶属度，然后不断更新。

$$c_i = \frac{\sum_{j=1}^n u_{ij}^{\alpha} x_j}{\sum_{j=1}^n u_{ij}^{\alpha}} \quad u_{ij} = \frac{1}{\sum_{k=1}^m \left( \frac{\|x_j - c_i\|}{\|x_j - c_k\|} \right)^{\frac{2}{\alpha-1}}}$$



# FCM计算举例

例1：设有4个数据，利用FCM算法聚成2类（加权指数参数是2）。已知某次迭代中隶属度如下，求下一次迭代聚类中心 $c_1'$ 和 $c_2'$ 。

$$x_1 = (2,2) \quad x_2 = (2,3) \quad x_3 = (4,8) \quad x_4 = (4,7)$$

$$u_{11} = 0.1 \quad u_{12} = 0.3 \quad u_{13} = 0.5 \quad u_{14} = 0.7$$

$$u_{21} = 0.9 \quad u_{22} = 0.7 \quad u_{23} = 0.5 \quad u_{24} = 0.3$$



# FCM计算举例

$$c'_1 = \frac{0.1^2 \times (2,2) + 0.3^2 \times (2,3) + 0.5^2 \times (4,8) + 0.7^2 \times (4,7)}{0.1^2 + 0.3^2 + 0.5^2 + 0.7^2}$$
$$= (3.76, 6.81)$$

$$c'_2 = \frac{0.9^2 \times (2,2) + 0.7^2 \times (2,3) + 0.5^2 \times (4,8) + 0.3^2 \times (4,7)}{0.9^2 + 0.7^2 + 0.5^2 + 0.3^2}$$
$$= (2.41, 3.49)$$



# FCM的MATLAB实现

- 已经编写好的FCM子程序引用格式如下：

```
[center,U,obj_fcn] = FCM(x,m,options);
```

```
[center,U,obj_fcn] = FCM(x,m);
```

- 其中options是一个 $4 \times 1$ 列向量，诸分量含义如下：

options(1): 隶属度指数 $\alpha > 1$

options(2): 最大迭代次数

options(3): 隶属度最小变化量，迭代终止条件


options(4): 每次迭代是否输出信息标志

- 当options缺省时，默认值为： $[2, 100, 10^{(-5)}, 1]$ 。



# FCM程序应用

例2：在MATLAB环境下，使用随机数生成1000个疏密不一的二维数据，再利用FCM子程序进行聚类。要求聚成2、3、4和5类。将结果去掉外框，用不同颜色以散点形式显示出来。同时画出目标函数值随着迭代次数的变化图象。




# 随机数据的生成和显示

- 平面随机点的生成，需要生成一定范围内的随机横坐标和纵坐标。这里可以使用rand或者其类似函数。直接使用plot函数并附加对应的符号就可以描绘批量散点而不划线。疏密不一致的散点，只需进行多次叠加即可。


```
a1=5;a2=55;b1=5;b2=55;  
x=a1+(a2-a1)*rand(100,1);  
y=b1+(b2-b1)*rand(100,1);  
figure;plot(x,y,'*');  
box off;
```

# 随机数据的生成和显示







# 分2类结果




# 分2类结果




# 分3类结果




# 分3类结果




# 分4类结果




# 分4类结果



# 分5类结果




# 分5类结果







# 正态分布的数据




# 正态分布的数据分4类结果




# 正态分布的数据分4类结果



# 正态分布的数据分3类结果



# 正态分布的数据分3类结果





# 算法讨论

- FCM算法是一种收敛算法，而随着数据数量、分布复杂度和聚类数量的增加，同等条件下的收敛速率也可能会变慢（并非绝对）。
- 对于正态分布的数据来说，FCM算法收敛快，且分类效果良好；而对于无规律分布的孤立点（也叫做野点）比较敏感，容易造成错分类。



# FCM算法在不同领域的拓展

- 在图像处理领域，FCM算法需要结合图像的邻域信息不断更新，例如给目标函数后加上一项邻域信息约束，从而得到对应的聚类中心和隶属度更新公式（如FLICM等）。
- 在大数据处理领域，FCM算法需要被加速运行，同时保证其精确度不能有过多的丢失。因此要从算法层面对FCM的公式进行优化，还需要要使用并行计算的硬件（如GPU）加速运行。





**THANK YOU!**